

Projektarbeit im 1. Sem. Informatik

Studiengang Wirtschaftsingenieurwesen, DHBW Stuttgart (Prof. Heuser)

Projekt 3 („Corona-Daten RKI“) – mittelschwer-schwer

Als Grundlage zu dieser Projektarbeit dienen folgende Dateien:

- 102_rki_covid19_stud.py (zu ergänzende Python-Datei)
- 102_RKI_COVID19_extract.csv (Grunddaten als Auszug der Komplettdaten im CSV-Format)
- 102_RKI_COVID19.csv (Komplettdaten im CSV-Format)

Die Dateien 102_RKI_COVID19.csv bestehen jeweils aus *realen(!) Coronadaten* des Robert-Koch-Instituts Berlin (RKI) eines bestimmten Erfassungsdatums, welche Sie mit Hilfe von 102_rki_covid19_stud.py weiter analysieren sollen. Da 102_RKI_COVID19.csv typischerweise zu groß zur Analyse auf Ihrem PC ist, wurde im Vorfeld mit 102_RKI_COVID19_extract.csv bereits ein Auszug dieser Komplettdaten angelegt, über welche die eigentliche Analyse erfolgen soll.

	A	B	C	D	E	F	G	H	I	J	K	L						
1	FID	IdBundesland	Bundesland	Landkreis	Altersgruppe	Geschlecht	AnzahlFall	AnzahlTodesfall	Meldedatum	IdLandkreis	Datenstand	NeuerFall	NeuerTodesfall	Refdatum				
2	42545207	1	Schleswig-Holstein	SK Flensburg	A00-A04	M	1	0	2020/09/30 00:00:00	01001	"09.10.2020, 00:00 Uhr"	0	-9	2020/09/30 00:00:00	-9	0	0	Nicht Ã¼bermittelt
3	42545208	1	Schleswig-Holstein	SK Flensburg	A00-A04	W	1	0	2020/08/24 00:00:00	01001	"09.10.2020, 00:00 Uhr"	0	-9	2020/08/24 00:00:00	0	1	0	Nicht Ã¼bermittelt
4	42545209	1	Schleswig-Holstein	SK Flensburg	A00-A04	W	1	0	2020/09/26 00:00:00	01001	"09.10.2020, 00:00 Uhr"	0	-9	2020/09/26 00:00:00	-9	0	0	Nicht Ã¼bermittelt
5	42545210	1	Schleswig-Holstein	SK Flensburg	A05-A14	M	1	0	2020/09/25 00:00:00	01001	"09.10.2020, 00:00 Uhr"	0	-9	2020/09/21 00:00:00	0	1	1	Nicht Ã¼bermittelt
6	42545211	1	Schleswig-Holstein	SK Flensburg	A05-A14	M	1	0	2020/09/26 00:00:00	01001	"09.10.2020, 00:00 Uhr"	0	-9	2020/09/21 00:00:00	0	1	1	Nicht Ã¼bermittelt
7	42545212	1	Schleswig-Holstein	SK Flensburg	A05-A14	M	1	0	2020/09/26 00:00:00	01001	"09.10.2020, 00:00 Uhr"	0	-9	2020/09/26 00:00:00	-9	0	0	Nicht Ã¼bermittelt
8	42545213	1	Schleswig-Holstein	SK Flensburg	A05-A14	W	1	0	2020/08/15 00:00:00	01001	"09.10.2020, 00:00 Uhr"	0	-9	2020/08/15 00:00:00	0	1	0	Nicht Ã¼bermittelt
9	42545214	1	Schleswig-Holstein	SK Flensburg	A05-A14	W	1	0	2020/09/24 00:00:00	01001	"09.10.2020, 00:00 Uhr"	0	-9	2020/09/23 00:00:00	0	1	1	Nicht Ã¼bermittelt
10	42545215	1	Schleswig-Holstein	SK Flensburg	A05-A14	W	1	0	2020/09/26 00:00:00	01001	"09.10.2020, 00:00 Uhr"	0	-9	2020/09/26 00:00:00	-9	0	0	Nicht Ã¼bermittelt

Abb. 1: Ausschnitt aus der Datei 102_RKI_COVID19_extract.csv

Die Python-Datei gibt dabei in Form des sogenannten Jupyter Notebooks nacheinander bzw. auf Wunsch des Benutzers folgende Analyseergebnisse aus (s.a. Abb. 2):

1. data overview
2. data description
3. exploratory data analysis

```

PS D:\Lehre\Sem 1\Python> & C:/Users/heuser/anaconda3/python.exe "d:/Lehre/Sem 1/Python/102_rki_covid19.py"
df_raw.head():
   FID  IdBundesland  Bundesland  ... AnzahlGenesen  IstErkrankungsbeginn  Altersgruppe2
0  42545207         1 Schleswig-Holstein  ...          0                   0  Nicht übermittelt
1  42545208         1 Schleswig-Holstein  ...          1                   0  Nicht übermittelt
2  42545209         1 Schleswig-Holstein  ...          0                   0  Nicht übermittelt
3  42545210         1 Schleswig-Holstein  ...          1                   1  Nicht übermittelt
4  42545211         1 Schleswig-Holstein  ...          1                   1  Nicht übermittelt

[5 rows x 18 columns]

Continue with data overview (y/n)? (CTRL-C to abort) y

Rows      : 248776
Columns   : 18

Features :
['FID', 'IdBundesland', 'Bundesland', 'Landkreis', 'Altersgruppe', 'Geschlecht', 'AnzahlFall', 'AnzahlTode-
tum', 'IdLandkreis', 'Datenstand', 'NeuerFall', 'NeuerTodesfall', 'Refdatum', 'NeuGenesen', 'AnzahlGenesen'
sbeginn', 'Altersgruppe2']

Missing values : 0

Unique values :
FID                248776
IdBundesland        16
Bundesland          16
Landkreis           413
Altersgruppe         7
Geschlecht           3
AnzahlFall           47
AnzahlTodesfall       9
Meldedatum           239
IdLandkreis          412
Datenstand           1

```

Abb. 2: Start des Programms 102_rki_covid19_stud.py inkl. der beiden ersten Analyseergebnisse (Ausschnitt)

Im zweiten Schritt sollen nun die Analyseschritte in 102_rki_covid19_stud.py sinnvoll ergänzt werden. Dabei ist Ihre Kreativität bei der Datenanalyse gefragt. Sinnvoll wäre bspw. die Analyse von:

4. data analysis: Neue Todesfälle
5. data analysis: Baden-Württemberg

Die Python-Datei 100_parse_csv_stud.py startet dabei nach der Kommentarzeile # __main__ (Zeile 25) und ruft nacheinander verschiedene Datenanalyseabschnitte bzw. Funktionen innerhalb der gleichen Python-Datei auf.

Ihre Aufgabe im Team

Halten Sie sich bei der Bearbeitung der Aufgabe zunächst immer an die allgemeinen Projektvorgaben aus der Datei „Projektarbeit“!

Spezielle Projektaufgaben:

1. Ergänzen Sie __main__ um weitere sinnvolle Datenanalyseabschnitte bzw. Funktionen. Dabei sollten Sie zumindest die weiter oben bezeichneten Analysen (Punkte 4 und 5) realisieren.
2. Fügen Sie jeder der oben bezeichneten Analyse eine graphische Visualisierung hinzu (z.B. mit Hilfe der Visualisierungs-Library „matplotlib“: <https://matplotlib.org/>).
3. Interpretieren Sie die Daten bzw. die daraus resultierende graphische Visualisierung.

Optionale Projektaufgaben:

4. (Optional 1) Fügen Sie nach Ihrer Interpretation der Daten weitere sinnvolle Analyseschritte und graphische Visualisierungen hinzu, um Ihre zuvor gewonnenen Erkenntnisse aus Punkt 3 weiter zu vertiefen oder zu ergänzen. Hier ist ganz besonders Ihre Kreativität gefragt!

Das Team, welches sich *besonders programmiersicher* fühlt und es sich zutraut kann sich beispielsweise an einem der folgenden Probleme versuchen:

5. (Optional 2) Versuchen Sie, die Graphik unter https://experience.arcgis.com/experience/478220a4c454480e823b17327b2bf1d4/page/page_0/ mit Hilfe von 102_rki_covid19_stud.py nachzubilden. Stimmen beide Graphiken überein? Worin unterscheiden sich beide? Was sind die Gründe für die Unterschiede?
6. (Optional 3) Versuchen Sie aktuelle Fallzahlen vom RKI unter https://www.rki.de/DE/Content/InfAZ/N/Neuartiges_Coronavirus/Daten/Fallzahlen_Daten.html zu beziehen, um weitere Analyseerkenntnisse zu gewinnen.

Zusatzfragen

Mögliche Fragen zu Ihrem Projekt könnten sein:

1. Erklären Sie bitte die unterschiedlichen Aufgaben oder Ziele der Libraries numpy, pandas, seaborn und matplotlib.
2. Was verstehen Sie unter dem Jupyter Notebook? Welche Unterschiede gibt es zur Python-Programmierung unter Visual Studio Code bzw. Visual Studio Community?

Mögliche *weitergehende* Fragen (*) könnten auch sein:

1. Beschreiben Sie die Site <https://www.kaggle.com/>: Welche Datasets werden über diese Site angeboten. Welche Aufgabenstellungen bzw. Datenanalysen werden den interessierten Datenwissenschaftlern präsentiert? Was bezeichnen die ‚Competitions‘?

Hilfe

Für sämtliche graphische Funktionen der Libraries Matplotlib, Pandas und darüber hinaus stehen Ihnen viele nützliche Websites als Hilfe zur Verfügung. Sollten Sie also Funktionsdetails der Bibliotheken oder Beispiel-Anwendungen mit Hilfe der Bibliotheksfunktionen nachschlagen wollen, so sei Ihnen folgende URL empfohlen:

- <https://docs.python.org/3.9/> (sämtliche in Python integrierte Funktionen inkl. Library Reference und Tutorial; Python Version 3.9 oder neuere)
- <https://matplotlib.org/stable/tutorials/introductory/pyplot.html> (Pyplot)
- https://pandas.pydata.org/pandas-docs/stable/user_guide/10min.html (Pandas)
- <https://realpython.com/beginners-guide-python-turtle/> (Turtle)
- ...

Häufig ist es auch ratsam, mit Hilfe von Google nach Hilfen im Web zu suchen.